

# Ghi chép đọc — STL & Loess

Seasonal-Trend decomposition using Loess

Topic Team AIO2026 — So sánh DLinear & NLinear

WEEK02 Reading Note — Cornell (bảng); scan tay ở Phụ lục

**Nguồn:** Cleveland et al., *STL: A Seasonal-Trend Decomposition Procedure Based on Loess*; Hyndman & Athanasopoulos, *Forecasting: Principles and Practice* (FPP3), ch. decomposition / STL.

**Mục tiêu note:** Hiểu Loess + STL (và robustness) để đo đặc trưng  $F_T$ ,  $F_S$  cho RQ1.

**Scan tay gốc:** Phụ lục A.

## 1. Loess — local smoother

Bảng 1: Cornell — Loess (Locally Estimated Scatterplot Smoothing).

| Cue / Question              | Detail                                                                                                                                                                                                                                                                                                                                                                                                                |
|-----------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| What is Loess?              | <b>Locally Estimated Scatterplot Smoothing:</b> tại mỗi điểm, fit hồi quy tuyến tính có trọng trên các điểm lân cận — $x$ gần quan trọng hơn $x$ xa.<br>Dùng nhiều trong time series / STL để trích <b>trend</b> mượt và <b>seasonal subseries</b> .                                                                                                                                                                  |
| Input                       | Các cặp $(x_i, y_i)$ ; với chuỗi thời gian: $x_i$ = chỉ số thời gian, $y_i$ = giá trị.                                                                                                                                                                                                                                                                                                                                |
| Hyperparam: span?           | Cửa sổ $k$ ( $k$ điểm gần nhất quanh focal), hoặc $\alpha \in [0, 1]$ với $k \approx \alpha \cdot n$ ( $\alpha$ thường $\approx 0.3$ – $0.75$ ).<br>$k/\alpha$ lớn $\rightarrow$ mượt hơn; nhỏ $\rightarrow$ bám nhiều / chi tiết hơn.                                                                                                                                                                                |
| Thuật toán (mỗi focal $i$ ) | Lấy $k$ điểm có $ x_j - x_i $ nhỏ nhất.<br>Khoảng cách: $d_j =  x_j - x_i $ ; chuẩn hóa $u_j = d_j / \max_j(d_j) \in [0, 1]$ (focal: $d = 0 \Rightarrow u = 0 \Rightarrow$ trọng lớn nhất).                                                                                                                                                                                                                           |
| Tricube kernel              | Nếu $ u  < 1$ : $w(u) = (1 -  u ^3)^3$ ; else $w = 0$ . $W = \sum_j w_j$ .                                                                                                                                                                                                                                                                                                                                            |
| Weighted local linear       | Fit $y \approx \beta_0 + \beta_1 x$ bằng cách minimize $L = \sum_j w_j (y_j - \beta_0 - \beta_1 x_j)^2$ .<br>$\bar{t}_w = W^{-1} \sum w_j t_j$ , $\bar{y}_w = W^{-1} \sum w_j y_j$ ;<br>$\beta_1 = \frac{\sum_j w_j (t_j - \bar{t}_w)(y_j - \bar{y}_w)}{\sum_j w_j (t_j - \bar{t}_w)^2}, \quad \beta_0 = \bar{y}_w - \beta_1 \bar{t}_w.$<br>$\hat{y}_i = \beta_0 + \beta_1 x_i$ = giá trị đã làm mượt tại focal $i$ . |

Scan tay: Hình 1.

## 2. STL — Seasonal-Trend + Loess

Bảng 2: Cornell — STL: phân rã trend / seasonal / residual.

| Cue / Question    | Detail                                                                                                                                                                                                                                                       |
|-------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| STL là gì?        | Seasonal-Trend decomposition using <b>Loess</b> : $y_t = T_t + S_t + R_t$ (cộng tính).                                                                                                                                                                       |
| Khởi đầu (loop 0) | Trend tạm: $MA(n)$ ; seasonal tạm: $x - \text{trend}_{MA}$ . Sau đó thay MA bằng Loess và lặp.                                                                                                                                                               |
| Loess dùng đâu?   | (1) Loess trên chuỗi <b>đã khử mùa</b> $\rightarrow$ trend trung bình.<br>(2) Loess trên <b>seasonal subseries</b> (gom theo tuần / tháng / ...) $\rightarrow$ thành phần mùa.<br>Cân giữa seasonal: trừ $\text{mean } s_s - \text{mean}(s_1, \dots, s_m)$ . |
| Residual          | $R = \text{original} - \text{trend} - \text{seasonal}$ . Lặp cho đến khi các thành phần ổn định.                                                                                                                                                             |
| Summary           | Loess = weighted local linear (tricube theo index/time). STL gọi Loess <b>hai</b> nhánh (trend + seasonal), iterate.                                                                                                                                         |

Scan tay: Hình 2 (phần trên).

## 3. Robustness weights (outer loop)

Bảng 3: Cornell — STL xử lý outlier bằng robustness weights.

| Cue / Question       | Detail                                                                                                                     |
|----------------------|----------------------------------------------------------------------------------------------------------------------------|
| Self-check: outlier? | STL <b>giảm trọng</b> các điểm residual lớn, rồi chạy lại Loess $\Rightarrow$ outlier hầu như không kéo trend / seasonal.  |
| Inner loop           | Ước lượng $T_t, S_t \rightarrow r_t = y_t - T_t - S_t$ .                                                                   |
| Outer (robust) loop  | Đổi $ r_t $ thành $\rho_t \in [0, 1]$ , nhân vào Loess lần sau. $ r_t $ lớn $\Rightarrow \rho_t$ nhỏ $\Rightarrow$ bỏ qua. |
| Bisquare             | $h = 6 \cdot \text{median}( r_t )$ , $u_t =  r_t /h$ .<br>Nếu $ u_t  < 1$ : $\rho_t = (1 - u_t^2)^2$ ; else $\rho_t = 0$ . |

Scan tay: Hình 2 (phần Self-check).

## 4. Đặc trưng $F_T$ , $F_S$ & hướng nhóm

Bảng 4: Cornell — từ STL  $\rightarrow$  strength metrics (Hyndman / FPP3) cho RQ1.

| Cue / Question   | Detail                                                                                                                                                     |
|------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Vì đo STL?       | RQ1: đặc trưng dữ liệu nào dự đoán DLinear thắng hay NLinear thắng? STL cho $T, S, R \rightarrow$ đo $F_T, F_S$ .                                          |
| Công thức (FPP3) | $F_T = \max(0, 1 - \text{Var}(R)/\text{Var}(T + R))$ , $F_S = \max(0, 1 - \text{Var}(R)/\text{Var}(S + R))$ . Nằm trong $[0, 1]$ ; càng gần 1 càng “mạnh”. |
| Period STL       | Theo sampling: ETTh theo giờ $\rightarrow 24$ ; chuỗi ngày $\rightarrow 7$ (hoặc 365 nếu đủ dài). Ghi rõ trong profile WEEK02.                             |
| vs. DLinear MA   | DLinear: decomp <b>một lần</b> bằng $\text{MA}_m + 2$ Linear. STL: Loess + iterate (+ robust) — do profile, <b>không</b> thay MA trong model.              |
| Pipeline nhóm    | <code>src/data_chars.py</code> : fit STL $\rightarrow F_T, F_S \rightarrow$<br><code>WEEK02_Data_Profiles.csv</code> ; W4 scatter gap MSE vs. strength.    |

| Khái niệm | Ý chính                          | Vai trò trong topic                    |
|-----------|----------------------------------|----------------------------------------|
| Loess     | Local weighted linear            | Engine làm mượt trong STL              |
| STL       | $y = T + S + R + \text{iterate}$ | Tách thành phần $\rightarrow F_T, F_S$ |
| Robust    | Bisquare $\rho_t$                | Ít bị outlier kéo component            |
| DLinear   | $\text{MA} + 2$ Linear           | Decomp <i>trong</i> model (khác STL)   |

## Tài liệu

- Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. *STL: A Seasonal-Trend Decomposition Procedure Based on Loess* (Journal of Official Statistics, 1990).
- Hyndman, R. J. & Athanasopoulos, G. *Forecasting: Principles and Practice* (3rd ed) — <https://otexts.com/fpp3/stl.html>.
- Cornell handwritten scans — Phụ lục A; file gốc `Figures/`.
- Outline nhóm: `Working_Files/WEEK01_Outline.md`.
- Pipeline: `EXECUTION_PLAN.md` mục 2.2 (`data_chars.py`).

## A. Scan Cornell notes gốc

Đối chiếu với các bảng 1–3.

| STL - seasonal decomp of time series by loess                   |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
|-----------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ques/Question                                                   | Detail                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
| What is loess?                                                  | <ul style="list-style-type: none"> <li>- <b>Locally Estimated Scatterplot Smoothing</b>: is a local smoother: at each point, fit a weighted linear reg using nearby points so nearby <math>x</math>'s matter more than far ones</li> <li>- Used a lot in time series / STL to extract smooth trend (and seasonal subseries)</li> </ul>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
| Algorithm                                                       | 1. Input: series pairs $(x_i, y_i)$ - for time series<br>$x_i$ = time axis $x$ (zero-based)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| Loess hyperparam?                                               | $y_i$ = value of the time series                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
| How does window size affect smoothing?                          | <ul style="list-style-type: none"> <li>- span: <math>k</math> window size (<math>k</math> closest points to the focal point)</li> <li>or <math>\alpha \in [0, 1]</math> with <math>k \approx \alpha \cdot n</math> (<math>\alpha</math> common <math>\approx 0.3-0.5</math>)</li> </ul> 2. For each focal point $i = 1, \dots, n$ : <ul style="list-style-type: none"> <li>- Take <math>k</math> closest points with smallest <math> x_j - x_i </math>.</li> <li>- Calculate distance:               <ul style="list-style-type: none"> <li>• <math>d_{-j} =  x_j - x_i </math></li> <li>• <math>u_{-j} = d_{-j} / \max(d_{-j}) \rightarrow</math> max norm [0, 1]</li> </ul> </li> <li><math>\Rightarrow</math> focal point has <math>u_{-j} = 0 \rightarrow</math> largest weight later</li> <li>- <b>Tricube kernel</b> (<math>p=3</math> usually, <math>w = (1 -  u ^p)^p</math>)               <ul style="list-style-type: none"> <li>• if <math> u  &lt; 1</math>: <math>w(u) = (1 -  u ^3)^3</math></li> <li>• else: <math>w(u) = 0</math>, <math>W = \sum w(u)</math></li> </ul> </li> <li><math>\Rightarrow</math> these are <math>w_{-j}</math> kernel weights</li> <li>- <b>Weighted local linear regression</b>:               <ul style="list-style-type: none"> <li>• Fit <math>y \approx \beta_0 + \beta_1 x</math> by minimizing</li> </ul> </li> </ul> |
| What expression are we minimizing in weighted local linear reg? | $S = \sum_j w_{-j} (y_{-j} - \beta_0 - \beta_1 x_{-j})^2$ <p>(closed form: calculated weighted means <math>\bar{t}_w</math> and <math>\bar{y}_w</math>)</p> $\bar{t}_w = \bar{t}_w = \frac{1}{W} \sum_j w_j t_j \quad \bar{y}_w = \frac{1}{W} \sum_j w_j y_j$ $\beta_1 = \frac{\sum_j w_j (t_j - \bar{t}_w)(y_j - \bar{y}_w)}{\sum_j w_j (t_j - \bar{t}_w)^2} \quad \beta_0 = \bar{y}_w - \beta_1 \bar{t}_w$                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |

Hình 1: Scan tay — Loess (tương ứng Bảng 1).

| Que/Question                  | Detail                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|-------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                               | <ul style="list-style-type: none"> <li>- Smoothed value <math>\hat{y}_i = \beta_0 + \beta_1 x_i</math></li> </ul>                                                                                                                                                                                                                                                                                                                                                               |
| In STL                        | <ul style="list-style-type: none"> <li>3. Output: series of <math>\{y_i\}</math> - locally smoothed of <math>y</math></li> </ul>                                                                                                                                                                                                                                                                                                                                                |
| start with                    | <ul style="list-style-type: none"> <li>- Deseasonalized <math>\rightarrow</math> Loess on that series <math>\rightarrow</math> trend</li> </ul>                                                                                                                                                                                                                                                                                                                                 |
| trend = MA(m)                 | <ul style="list-style-type: none"> <li>- Loess on seasonal subseries (group by Week, month)</li> </ul>                                                                                                                                                                                                                                                                                                                                                                          |
| seasonal = $x - \text{trend}$ | <ul style="list-style-type: none"> <li><math>\rightarrow</math> seasonal <math>\rightarrow</math> center <math>s - s \leftarrow s - s - \text{mean}(s_1, \dots, s_m)</math></li> <li>- Residual = original - trend - seasonal.</li> <li>- Iterate until component stabilize</li> </ul>                                                                                                                                                                                          |
| Summary                       | <ul style="list-style-type: none"> <li>- Loess smooth by <math>x</math>-neighborhood weighted linear fits.</li> <li>- Distance is index / time (<math>x</math>), weights come from a tricube kernel</li> <li>- <math>\hat{y}_i</math> is the fitted value at each point</li> <li>- STL use Loess 2 times, on trend and seasonal series until it is stabilized.</li> <li>- At loop 0 trend is calculated with MA(m) and seasonal = <math>x - \text{trend}_{MA}</math></li> </ul> |
|                               | Self-check:                                                                                                                                                                                                                                                                                                                                                                                                                                                                     |
|                               | 1. How does STL handle outliers using robustness weights?                                                                                                                                                                                                                                                                                                                                                                                                                       |
|                               | $\Rightarrow$ STL down weights points with huge residual, then re-run Loess so outliers barely pull trend/seasonal                                                                                                                                                                                                                                                                                                                                                              |
|                               | Idea:                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
|                               | Inner loop: estimate trend + seasonal $\rightarrow$ residual                                                                                                                                                                                                                                                                                                                                                                                                                    |
|                               | $r_t = y_t - \text{trend}_t - \text{seasonal}_t$                                                                                                                                                                                                                                                                                                                                                                                                                                |
|                               | Outer (robust) loop: turn $ r_t $ into robustness weights                                                                                                                                                                                                                                                                                                                                                                                                                       |
|                               | $p_t \in [0, 1]$ , multiply them into next Loess fits.                                                                                                                                                                                                                                                                                                                                                                                                                          |
|                               | Big $ r_t  \rightarrow$ small $p_t \rightarrow$ ignored.                                                                                                                                                                                                                                                                                                                                                                                                                        |
|                               | $n = 6 \Rightarrow \text{median}( r_t )$ $u_t = \frac{ r_t }{\text{median}( r_t )}$                                                                                                                                                                                                                                                                                                                                                                                             |
|                               | if $ u_t  < 1$ : $p_t = (1 - u_t^2)^{2n}$                                                                                                                                                                                                                                                                                                                                                                                                                                       |
|                               | else $p_t = 0$                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |

Hình 2: Scan tay — STL + robustness (tương ứng Bảng 2, 3).